UNIVERSIDAD CENFOTEC · MAESTRÍA

NYC Yellow Taxi MLOps

Plataforma reproducible para estimar la duración de viajes en taxi amarillo de Nueva York

Informe de avance: problema, objetivo, datos, metodología y resultados alcanzados.

INTEGRANTES

Bernal Rojas · Jorge Garnier · Jorge Bermúdez

CURSO

Tópicos Especiales en Analítica de Datos

ESTADO DOCUMENTADO AL

5 de noviembre de 2026

Repositorio del proyecto: github.com/ModoJorgeBT/nyc-yellow-taxi-mlops

01 · CONTEXTO Y DATOS

Problema y propósito

El proyecto busca estimar, al inicio del viaje, cuánto durará un recorrido en taxi amarillo de Nueva York. El reto no es solo predecir: también demostrar un ciclo de aprendizaje automático trazable, reproducible y controlado desde la ingestión de datos hasta la operación.

> **Objetivo general.** Construir una plataforma MLOps modular que ingiera datos mensuales de NYC TLC, controle su calidad, prepare variables, entrene y compare modelos, y deje preparada la ruta hacia el registro, servicio API, monitoreo y reentrenamiento con decisiones auditables.

Pregunta de trabajo

¿Qué duración en minutos puede estimarse al comenzar un viaje usando únicamente información disponible en ese momento, y cómo se puede evaluar y operar esa predicción sin fuga de información?

Fuentes y alcance de los datasets

- **Fuente principal:** registros mensuales de viajes NYC TLC Yellow Taxi en formato Parquet, correspondientes a enero de 2024–diciembre de 2025 (24 meses).
- **Volumen original reportado:** 1,418 GiB y 89.892.322 filas declaradas en los metadatos/footers de los archivos. El conteo describe el inventario; no equivale a filas finalmente elegibles.
- **Esquema:** 19 columnas en los archivos de 2024 y 20 en 2025, debido a la incorporación de `cbd_congestion_fee`.
- **Datos derivados:** lotes validados, archivos de features y etiqueta de duración, contexto de auditoría y particiones temporales. Los datos reales permanecen locales y no están versionados en GitHub.
- **Pruebas:** fixtures Parquet sintéticas pequeñas para validar reglas y reproducibilidad; no representan los viajes reales ni se usan para informar métricas del modelo.

Partición cronológica aprobada

Conjunto	Periodo	Filas auditadas	Uso
Train	Todo 2024	41.119.495	Ajuste de preprocesamiento y modelos
Validation	Enero–marzo 2025	11.163.264	Comparación y selección de modelos
Test	Abril–junio 2025	12.712.466	Evaluación final de baseline/SGD/MLP
Replay	Julio–diciembre 2025	24.266.924	Preparación para monitoreo; sin métricas predictivas

Las particiones contienen 89.262.149 filas publicadas tras los controles y cortes temporales auditados. No deben confundirse con las filas declaradas en los footers de los Parquet originales.

Del dato al experimento

El flujo se construyó por etapas, separando las decisiones metodológicas de la ejecución y dejando evidencia para reproducir cada resultado.

Etapa	Trabajo realizado	Resultado
Fundamentos (T01–T03)	Definición del problema, arquitectura local, reglas de alcance y entorno Python reproducible.	Especificación, plan, decisiones y estructura modular.
Datos (T04–T11)	Fixtures de prueba, perfilado, descarga/registro mensual, manifiestos, hashes, reglas de calidad e ingesta controlada.	Pipeline raw → validado con reportes y bloqueo explícito ante fallos críticos.
Features (T12–T13)	Etiqueta de duración, tratamiento temporal, variables causales y transformación compartida entre entrenamiento e inferencia.	Features auditables sin variables posteriores al inicio.
Preparación (T14)	Procesamiento de los 24 meses, control de excepciones y cortes cronológicos; auditoría de identidad y valores por partición.	Cuatro conjuntos completos verificados; 24 versiones de features.
Modelado (T15–T17)	Baseline, candidatos SGD Huber y MLP16, evaluación temporal; extensión LightGBM entrenada con train y evaluada solo en validation.	Comparación cuantitativa, auditorías independientes y resultados documentados.

Definición de la etiqueta y prevención de fuga

La duración se calcula como la diferencia entre las marcas de recogida y llegada, en minutos y en UTC, después de interpretar los tiempos históricos en *America/New_York*. Los horarios ambiguos o inexistentes por cambios de horario se apartan. La llegada se usa únicamente para construir la etiqueta histórica, nunca como predictor.

Variables disponibles al inicio

Zona de recogida, componentes del calendario de recogida y cantidad de pasajeros opcional con indicador de ausencia.

Variables excluidas

Destino (deshabilitado en la versión actual), distancia real, llegada, tarifa, propina, pago y demás importes o datos posteriores.

Evaluación

MAE como métrica principal; RMSE, MedAE y percentil 90 del error absoluto como métricas complementarias. Selección de la primera comparación con validation antes de consultar test.

Calidad y trazabilidad

Manifiestos, hashes, reglas configurables, reportes PASS/WARN/FAIL, excepciones puntuales y conservación de rechazos y exclusiones.

Limitación de procedencia: los 24 archivos reales se registraron como LOCAL_UNVERIFIED; la fuente y fecha de descarga se mantienen desconocidas. Nueve excepciones específicas adicionales permitieron procesar lotes con fallos medidos, excluyendo 543.725 filas inválidas y conservando los FAIL originales. La autorización no equivale a calidad perfecta ni habilita otros archivos.

03 · RESULTADOS Y ESTADO

Qué se ha logrado y qué falta

Resultados de modelos

Todas las métricas están en minutos. SGD fue elegido sobre validation antes de abrir el test. LightGBM se evaluó únicamente en validation conforme a la extensión aprobada.

Modelo	Validation MAE	Validation RMSE	Validation MedAE	Validation P90	Test MAE
Baseline (mediana)	7,741890	11,912962	5,583333	15,250000	9,032999
SGD Huber	6,876910	10,559177	4,515139	15,485330	7,965068
MLP16	11,856108	15,946811	9,250000	24,458932	10,717683
LightGBM	6,496404	9,847425	4,631360	13,478764	No evaluado

SGD redujo el MAE frente al baseline en 11,17 % en validation y 11,82 % en test. Sin embargo, su P90 de validation fue ligeramente mayor que el del baseline, por lo que la mejora no es uniforme en todos los errores. LightGBM obtuvo el menor MAE en validation, pero no se evaluó en test ni se declaró nuevo modelo campeón. Replay tampoco se utilizó para medir desempeño.

Estado del producto

Completado técnicamente

Ingesta y validación; features causales; particiones temporales auditadas; baseline y primera comparación de candidatos; entrenamiento/evaluación LightGBM en validation.

Pendiente

Revisión humana de resultados, evaluación final independiente de LightGBM, MLflow y registro, selección/promoción de champion, API, Docker/Compose, CI, monitoreo operativo y política de reentrenamiento/rollback.

Repositorio

https://github.com/ModoJorgeBT/nyc-yellow-taxi-mlops

> La documentación de este informe refleja el estado local del proyecto al 5 de noviembre de 2026. La continuación con el cierre T14, la comparación T16/T17 y la extensión LightGBM aún no se había publicado mediante un nuevo commit/push al momento de consolidar este resumen; por ello, el contenido del enlace puede no incluir todos estos avances.

Documentación de referencia

README.md · intent.md · docs/architecture.md · docs/t14-t15-quality-blocker.md · docs/t16-t17-validation.md · reports/quality/t14_completion.md · reports/evaluation/t17_model_comparison.md · reports/evaluation/lightgbm_validation.md.